

Portfolio

소개

UNIST(울산과학기술원) 산업공학과 석사 졸업 (2023)

LLM 기반 AI 서비스 개발 경험을 보유한 백엔드/AI 엔지니어입니다. vLLM, LangGraph, RAG 시스템 구축부터 데이터 파이프라인, API 서비스까지 End-to-End 개발 경험이 있습니다.

학위 논문

Personal recommender system via convolutional autoencoder with conditioning augmentation

Recommender system and representation learning with convolutional autoencoder

Kim, Sunjun (2023) | UNIST 산업공학과 석사

[논문 링크](#)

프로젝트 목록

구분	프로젝트	설명	역할
AIO2O	Skylife 영화 추천 시스템	임베딩 벡터 기반 영화 추천	벡터 DB 구축, 추천 알고리즘
AIO2O	부산관광공사 여행 챗봇	여행지 추천 챗봇 (상용 서비스)	벡터 DB 구축, 추천 알고리즘
Plantynet	AI LLM API	vLLM 기반 텍스트 처리 API 서비스	전체 개발
Plantynet	RAG 시스템	Milvus 기반 Agentic RAG 챗봇	데이터 전처리, 벡터 DB, 검색
Plantynet	Reflexion Agent	ReAct + Reflexion 자기개선 AI 에이전트	전체 설계 및 개발
Side Project	서울 상권분석 시스템	상권 데이터 수집 및 LLM Agent 분석	전체 개발

기술 스택

분류	기술
Language	Python
LLM/AI	vLLM, LangChain, LangGraph, LiteLLM, OpenAI API, HuggingFace
Vector DB	Milvus, Pgvector
Database	PostgreSQL, Oracle, Mysql
Backend	FastAPI, Uvicorn

Frontend	Streamlit, Gradio
Infra	Docker, Docker Compose
Embedding	BGE-M3, BGE-Reranker, Sentence-Transformers
Protocol	MCP (Model Context Protocol), SSE, JSON-RPC

프로젝트

[AIO2O] 1. Skylife 영화 추천 시스템

역할: 벡터 DB 구축, 추천 알고리즘 개발

임베딩 벡터 기반 영화 콘텐츠 추천 시스템. 영화 메타데이터를 벡터화하여 의미 기반 유사도 검색 구현.

주요 기능

- 영화 메타 정보 임베딩 (장르, 내용, 감독, 배우 등)
- PostgreSQL + pgvector 기반 벡터 DB 구축
- 메타 필터링 + 벡터 유사도 결합 추천 알고리즘

추천 알고리즘

- 1단계: 메타 필터링 (장르, 배우, 감독 조건 적용)
- 2단계: 벡터 유사도 검색 (영화 설명/내용 의미적 유사도)

기술 스택: Python, PostgreSQL, pgvector, Embedding Models

[AIO2O] 2. 부산관광공사 여행 스케줄링 챗봇

역할: 벡터 DB 구축, 추천 알고리즘 개발

자연어 질의 기반 여행 관광지 추천 챗봇. 현재 부산관광공사에서 상용 서비스 중.

주요 기능

- 여행지 관련 메타 데이터 임베딩 및 벡터 DB 구축
- 메타 필터링 + 벡터 유사도 결합 추천 알고리즘
- 여행 스케줄링 기능

추천 알고리즘

- 1단계: 메타 필터링 (지역, 여행 기간 1박/2박, 카테고리 등 조건 적용)
- 2단계: 벡터 유사도 검색 (여행지 설명, 후기, 활용 정보 의미적 유사도)

서비스 링크: [Visit Busan](#)

기술 스택: Python, Embedding Models, Vector DB, NLP

[Plantynet] 3. AI_LLM_API

역할: 전체 개발 담당

LLM 기반 텍스트 처리 API 서비스. vLLM 엔진을 FastAPI 프로세스 내에서 직접 구동하여 효율적인 추론 파이프라인 구축.

주요 기능

- 기사 요약 API (목표 길이 수렴 알고리즘 적용, 70~130% 범위 내 수렴)
- 긴 문서 축약 (Map-Refine 파이프라인: 불릿 추출 -> 평문 기사 변환)
- 주제 분류 및 분류체계(Taxonomy) 분석
- 키워드/태그 추출 (구조화된 출력 기반)
- Gradio UI 제공 (Chatbot, Summarization, Topic/Taxonomy Classification)

기술적 특징

- vLLM LLMEngine in-process 아키텍처
 - 토큰 레벨 연속 배칭으로 동시 요청 효율 향상
 - asyncio.Semaphore로 최대 동시 LLM 연산 슬롯 관리
- LangGraph 기반 에이전트 구현
 - SummarizationAgent: target_text_instructions와 적응형 재시도(+10%)
 - ReduceAgent: MAP-REFINE 파이프라인
 - KeywordAgent: 구조화된 출력 기반 태깅
 - AbstractAgent: 다중 기사 요약 통합
- API 버전 관리 (v0: 기본, v1: LangGraph 기반)

API Endpoints

```

POST /summarize_article      - 기사 요약
POST /summarize_magazine    - 긴문서 축약 (Map-Refine)
POST /classify_topic_from_article - 주제 분류
POST /classify_taxonomy_from_article - 분류체계 분석
POST /generate              - 자유 대화
  
```


기술 스택: Python, FastAPI, vLLM, LangGraph, LangChain, PyTorch, Gradio

[Plantynet] 4. RAG 시스템 (AI_PROMPT + RAG-Chatbot)

역할: 데이터 전처리, 벡터 DB 구현, 검색 기능 구현

Milvus 기반 Agentic RAG 시스템. 한국어 매거진/문서 검색과 생성형 AI를 결합한 질의응답 챗봇.

시스템 아키텍처



주요 기능

[검색 시스템]

- 하이브리드 검색: Dense 벡터 검색 + BM25 Sparse 키워드 검색 결합
- Reranking: BGE-Reranker-v2-M3 모델로 검색 결과 재정렬
- 컨텍스트 윈도우: 검색된 청크 주변 문맥 자동 확장 (window_size 설정)

- 날짜/매거진 필터링 지원

[Agent 시스템]

- Agentic RAG Loop: Safety Guard -> Reasoning -> Tool Calling -> Response
- LlamaGuard 기반 입출력 안전성 검증 (입력/출력 이중 검증)
- SSE 스트리밍 (token, message, timing, error 이벤트)
- Thread 기반 대화 히스토리 관리 (Checkpoint Store)
- MongoDB/PostgreSQL/SQLite 체크포인트 지원

기술적 특징

[임베딩 & 검색]

- BGE-M3 임베딩 모델 (1024차원 Dense Vector)
- BGE-Reranker-v2-M3 재정렬 모델
- COSINE 유사도 메트릭, nprobe=64
- 파라미터화된 검색 설정 (settings.py 중앙 관리)

[데이터 전처리]

- 100자 이상 청크 필터링
- 특수문자 제거 및 토큰 기반 검증
- KoNLPy 기반 한국어 텍스트 처리 최적화

[Agent 구현]

- LangGraph StateGraph 기반 그래프 구성
- AgentState: messages, remaining_steps, retrievals 관리
- wrap_model: SystemMessage 주입 + Tool 바인딩
- ToolNode로 milvus_search 실행 후 model로 재라우팅

코드 구조

```
src/agents/  
  rag_assistant.py    - RAG Agent 그래프 정의 (guard_input -> model -> tools)  
  milvus_tool.py      - MilvusRetriever 래퍼  
  tools.py            - milvus_search 도구 등록  
  llama_guard.py       - 안전성 검증  
  milvus_key_search/  - 검색 엔진 코어  
  
app/  
  rag_api.py          - FastAPI 검색 API  
  rag_query.py        - 쿼리 처리
```


기술 스택: Python, LangGraph, LangChain, FastAPI, Milvus, Streamlit, BGE-M3, BGE-Reranker, MongoDB, PostgreSQL

[Side Project] 6. 서울 상권분석 시스템 (sbiz_db + sbiz_llm)

역할: DB 스키마 구성/구축, LLM 구현, Prompt 구현, 백엔드/프론트엔드 구현

서울 열린데이터광장 상권 데이터를 수집하고, LLM Agent로 분석하는 End-to-End 시스템.

시스템 아키텍처



주요 기능

[데이터 수집 - sbiz_db]

- 서울 Open API 8개 상권 서비스 자동 동기화
- APISpec 클래스로 HTML 파싱 -> 메타데이터/스키마 추출
- download/export_csv 메서드 지원 (fallback 처리)
- pandas DataFrame 컬럼 매핑 (한글 -> 영문)
- UPSERT 방식 중복 없이 저장
- CLI 지원: --inf-id, --sync-all, --list, --validate

[LLM Agent - sbiz_llm]

- 쿼리 라우팅: rag (상권 질문) / chat (일반 대화) / reject (거부)
- Tool Calling 기반 PostgreSQL 동적 검색
- 9개 상권 테이블 지원
- 비동기 처리 (asyncpg)

지원 데이터 (9개 테이블)

테이블	설명	주요 컬럼
trdar_relm	상권 영역 (마스터)	trdar_cd, trdar_cd_nm, signgu_cd
trdar_selng	추정 매출	thsmon_selng_amt, ml/fml_selng_amt, 요일별/연령별
trdar_stor	점포 수	stor_co, opbiz_stor_co, clsbiz_stor_co
trdar_flpop	유동 인구	tot_flpop_co, 성별/연령별/요일별
trdar_rspop	상주 인구	tot_rspop_co, apt_hshold_co
trdar_wrcpop	직장 인구	tot_wrc_popltn_co, 성별/연령별
trdar_rent	임대료	rent_area_div_avg, rent_fee_div_avg
trdar_ix	상권 변화 지표	trdar_chnge_ix, opbiz_rt, clsbiz_rt
trdar_fclty	집객 시설	병원/은행/학교/지하철역 등 시설 수

기술적 특징

[데이터 동기화]

- inf_id 기반 서비스 정의 (OA-15560, OA-15572 등)
- 스키마 검증 후 DB 저장
- Primary Key 기반 UPSERT
- 크론잡 자동 동기화 지원

[LLM Agent]

- LangGraph StateGraph 기반 그래프
- Pydantic BaseModel로 Tool Input 스키마 정의
- PostgresSearchInput: table_name, stdr_yyqu_cd, trdar_cd, limit 등
- 시스템 프롬프트 중앙 관리 (src/core/prompts.py)

코드 구조

```
sbiz_db/
  data_sync.py      - 메인 동기화 서비스
  api_spec.py       - 서울 API 스펙 파서
  init_db/01_schema.sql - DB 스키마

sbiz_llm/src/
  agents/
    sbiz_agent.py    - LangGraph Agent
    tools/postgres_search.py - PostgreSQL 검색 도구
    subagents/query_router.py - 쿼리 라우팅
  core/
```

settings.py	- Pydantic Settings
prompts.py	- 시스템 프롬프트
service/	
service.py	- FastAPI 서비스


기술 스택: Python, LangGraph, FastAPI, PostgreSQL, asyncpg, pandas, BeautifulSoup4, psycpg2, Docker

[Plantynet] 5. Reflexion Agent (MCP Host)

역할: 전체 설계 및 개발 담당

LangGraph 기반 ReAct + Reflexion 패턴 자기 개선형 AI 에이전트. 자연어 명령으로 작업을 수행하고, 실패 시 원인을 분석하여 교훈을 학습하는 시스템. Atelier 프론트엔드와 호환되는 Product > Thread > Feed 계층 구조 리소스 관리 지원.

시스템 아키텍처



주요 기능

기능	설명
ReAct 패턴	Thought → Action → Observation 루프 기반 추론
Reflexion 패턴	실패 시 원인 분석 → 교훈 도출 → 장기 기억 저장 → 재시도
2단계 평가	규칙 기반 (에러 키워드) + LLM 기반 정밀 판단
장기 기억	problem/solution 형태로 교훈 저장, 유사 상황에서 재활용
Early Stopping	연속 실패 감지 시 조기 종료

리소스 계층 구조 (Atelier 호환)

```
Product (프로덕트)
├── Thread (스레드) - title, goal, startDate, endDate
│   └── Feed (피드) - title, content, category, comments
```

사용 가능한 도구 (17개)

분류	도구
Product	create, list, update, delete
Thread	create, list, update, delete
Feed	create, list, update, delete
Comment	add_comment
Utility	search_resources, get_summary, get_metadata

기술적 특징

- **LangGraph StateGraph**: 4개 노드 (Actor, Tool Executor, Evaluator, Reflection) 그래프 구성
- **다중 LLM 지원**: Google Gemini, OpenAI, Anthropic 전환 가능
- **설정 기반**: YAML 파일로 LLM, 에이전트, 프롬프트 설정 관리
- **메모리 시스템**: Short-term (세션 히스토리) + Long-term (교훈 저장소)

기술 스택: Python, LangGraph, LangChain, Google Gemini, OpenAI, Anthropic, Pydantic, YAML

연구 개발 자료

-  [Notion 연구 개발 노트](#)

연락처

- 이메일: cyon13022@gmail.com